



Institución
Universitaria
Reacreditada en Alta Calidad

ANÁLISIS EXPLORATORIO DE DATOS

PROGRAMACIÓN AVANZADA

170304004


www.itm.edu.co

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

En general, los datos están en todas partes: negocios, ciencia, salud, deportes. El reto de la ciencia de datos es entenderlos y explicarlos de forma clara.

Las herramientas de visualización y análisis ayudan a transformar tablas en historias con sentido, algunas de las principales son:

- Medidas estadísticas
- Histogramas
- Diagramas de dispersión (scatter plots)



- **Medidas estadísticas**

Las medidas estadísticas son valores que resumen y describen las características principales de un conjunto de datos. Ayudan a entender la información de manera rápida y sencilla.

Se dividen principalmente en dos categorías:


- Medidas de tendencia central
- Medidas de dispersión

- **Medidas estadísticas**

- Medidas de tendencia central


Media:

Es el promedio de los datos. Es ideal para datos numéricos sin valores extremos (atípicos), ya que estos distorsionan el resultado.




Mediana:

Es el **valor que se encuentra justo en el medio** de un conjunto de datos ordenado. No se ve afectada por los valores atípicos.




Moda:

Es el **valor que más se repite** en el conjunto de datos.



- **Medidas estadísticas**

- Medidas de dispersión (o variabilidad)



Rango:

Es la diferencia entre el **valor máximo** y el **valor mínimo**.

Varianza (s^2)


Mide qué tan lejos está cada valor del promedio. Una varianza alta significa que los datos están muy dispersos.

Desviación Estándar ($s = \sqrt{s^2}$)

Una desviación estándar baja indica que los datos tienden a estar cerca de la media, mientras que un valor alto indica que los datos están más dispersos.

- ## Histogramas


Un histograma es un gráfico de barras que visualiza la distribución de frecuencia de un conjunto de datos numéricos continuos. Ayuda a entender la forma, el centro y la dispersión de los datos.



- ## Histogramas

Los histogramas permiten identificar:

- **La forma de la distribución:** Si es simétrica (como una campana), sesgada (cola larga) a la derecha o sesgada a la izquierda.
- **Valores atípicos (outliers):** Barras aisladas y lejanas del resto.
- **Concentración de los datos:** Dónde se agrupan la mayoría de los valores.



- **Diagramas de dispersión (Scatter Plots)**

Son gráficos que se utiliza para visualizar la relación entre dos variables numéricas.

Cada punto en el gráfico representa una observación en los datos, con su posición determinada por los valores de las dos variables (una en el eje X y otra en el eje Y).

- **Diagramas de dispersión (Scatter Plots)**

Los Diagramas de dispersión permiten identificar:

➤ **Correlación:** Es su principal utilidad, ya que dice cómo se comporta una variable cuando la otra cambia. Puede clasificarse como **Correlación Positiva**, **Correlación Negativa** o **Sin Correlación**



3. Correlación lineal positiva alta



5. Correlación lineal negativa alta



1. No hay correlación



6. No hay correlación lineal


- Diagramas de dispersión (Scatter Plots)

Los Diagramas de dispersión permiten identificar:

Fuerza de la relación: Si los puntos están muy agrupados formando una línea clara, la relación es fuerte. Si están muy dispersos, es débil.



2. Correlación lineal positiva



3. Correlación lineal positiva alta

Identificación de outliers : Puntos que se alejan del patrón general del resto de los datos.



Institución
Universitaria
Reacreditada en Alta Calidad

¡MUCHAS GRACIAS!

Material de apoyo usado para las clases de Programación Avanzada
Elaborado por:

Esteban Gonzalez Valencia
estebangonzalez@itm.edu.co

... Hacia una era de
Universidad y Humanidad