



Institución
Universitaria
Reacreditada en Alta Calidad

LIMPIEZA DE DATOS

PROGRAMACIÓN AVANZADA

170304004

www.itm.edu.co

LIMPIEZA DE DATOS

Limpiar datos, “data cleaning” o depuración de datos, es el proceso de identificar, corregir o eliminar errores, inconsistencias e imprecisiones en un conjunto de datos.

El objetivo es asegurar que los datos sean precisos, completos y consistentes, lo que resulta en información de alta calidad.



LIMPIEZA DE DATOS

Limpiar datos, “data cleaning” o depuración de datos, es el proceso de

Si los datos están “**sucios**”, **cualquier análisis**, modelo de inteligencia artificial o reporte que generes a partir de ellos será **poco confiable** y podría llevar a decisiones equivocadas.

¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

La limpieza de datos es un paso fundamental en cualquier proyecto que involucre análisis de datos, ciencia de datos o aprendizaje automático (*machine learning*).



¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.



¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.
- **Aumenta la eficiencia:** Los científicos de datos dedican menos tiempo a lidiar con errores y más tiempo a extraer información.



¿POR QUÉ ES IMPORTANTE LIMPIAR LOS DATOS?

- **Mejora la precisión de los análisis:** Decisiones basadas en datos limpios y de alta calidad son mucho más acertadas.
- **Aumenta la eficiencia:** Los científicos de datos dedican menos tiempo a lidiar con errores y más tiempo a extraer información.
- **Resultados confiables en modelos de IA:** Los algoritmos de aprendizaje automático son tan buenos como los datos con los que se entrenan. Datos sucios generan modelos imprecisos y sesgados.



LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.

LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.

LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.
Datos incorrectos o inexactos	Información que no es correcta o no tiene sentido en el contexto.	Un cliente con una edad registrada de "200 años".

LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.
Datos incorrectos o inexactos	Información que no es correcta o no tiene sentido en el contexto.	Un cliente con una edad registrada de "200 años".
Inconsistencias de formato	Datos que deberían ser uniformes pero se presentan de diferentes maneras.	Fechas registradas como "10/05/2023", "10-May-2023" y "2023/05/10" en la misma columna.

LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.
Datos incorrectos o inexactos	Información que no es correcta o no tiene sentido en el contexto.	Un cliente con una edad registrada de "200 años".
Inconsistencias de formato	Datos que deberían ser uniformes pero se presentan de diferentes maneras.	Fechas registradas como "10/05/2023", "10-May-2023" y "2023/05/10" en la misma columna.
Valores atípicos (Outliers)	Puntos de datos que son significativamente diferentes del resto.	En un registro de salarios de una empresa, encontrar un valor de \$10 por mes para un analista.

LIMPIEZA DE DATOS

El proceso de limpieza se enfoca en detectar y solucionar varios tipos de problemas.



PROBLEMA	DESCRIPCIÓN	EJEMPLO
Datos duplicados	Registros idénticos o casi idénticos que aparecen más de una vez.	Tener registrado a "Juan Pérez" y a "Juan Perez" (sin tilde) como dos personas distintas.
Valores faltantes	Campos vacíos o nulos en el conjunto de datos.	Una encuesta donde un participante no respondió su edad.
Datos incorrectos o inexactos	Información que no es correcta o no tiene sentido en el contexto.	Un cliente con una edad registrada de "200 años".
Inconsistencias de formato	Datos que deberían ser uniformes pero se presentan de diferentes maneras.	Fechas registradas como "10/05/2023", "10-May-2023" y "2023/05/10" en la misma columna.
Valores atípicos (Outliers)	Puntos de datos que son significativamente diferentes del resto.	En un registro de salarios de una empresa, encontrar un valor de \$10 por mes para un analista.
Datos irrelevantes	Columnas o filas que no aportan valor al análisis que se quiere realizar.	En un análisis de ventas, tener una columna con el color de ojos del vendedor.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

- 1) Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

- 1) Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.
- 2) Eliminación de duplicados:** Se identifican y eliminan los registros repetidos.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

- 1) Inspección y perfilado:** El primer paso es explorar los datos para entender su estructura, calidad y encontrar las anomalías mencionadas anteriormente.
- 2) Eliminación de duplicados:** Se identifican y eliminan los registros repetidos.
- 3) Manejo de valores faltantes:** Se decide una estrategia para los datos ausentes. Las opciones comunes incluyen eliminar la fila completa, **imputar** (estimar) el valor basándose en otros datos (como la media o la mediana), o usar un algoritmo avanzado.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

4) Corrección de errores estructurales: Se estandarizan los formatos (fechas, números, texto), se corrigen errores tipográficos y se asegura la consistencia en las categorías.

- Se recomienda convertir variables categóricas a un formato numérico porque la gran mayoría de los algoritmos de machine learning y modelos estadísticos no pueden procesar texto o etiquetas directamente.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

- 5) Tratamiento de valores atípicos:** Se analizan los valores extremos para determinar si son errores o datos genuinos y se decide si deben eliminarse o ajustarse.

Pasos habituales en el proceso de limpieza

Aunque las herramientas y técnicas pueden variar, el proceso general de limpieza de datos suele seguir una secuencia lógica:

- 5) Tratamiento de valores atípicos:** Se analizan los valores extremos para determinar si son errores o datos genuinos y se decide si deben eliminarse o ajustarse.
- 6) Validación:** Una vez completada la limpieza, se realiza una última revisión para confirmar que los datos son consistentes y están listos para ser analizados.

EJEMPLO DE LIMPIEZA DE DATOS

1) Inspección y perfilado:

Antes de cambiar nada, necesitas entender tus datos. Un buen primer paso es cargar el archivo y usar tres funciones esenciales:

- **df, df.head(), df.tail()** para ver las primeras/últimas filas.
- **df.info()** para ver el tipo de dato de cada columna y cuántos valores no nulos hay.
- **df.isnull().sum()** para contar el total de valores faltantes por columna.
- **df.duplicated().sum()** para contar los registros duplicados

EJEMPLO DE LIMPIEZA DE DATOS

2) Eliminación de duplicados:

Elimina las filas duplicadas de tu DataFrame usando el comando

- **`df.drop_duplicates(inplace=True)`**

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Una primera opción es eliminar cualquier fila que tenga valores faltantes.

- `df = df.dropna()`

En algunos casos no es buena idea eliminar las filas con valores faltantes, porque se perdería mucha información.

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Otra solución consiste en "**Imputar**" los valores faltantes. Una estrategia simple y efectiva es rellenar los vacíos con la **mediana o la media**. Por ejemplo, supongamos que '**Columna**' tiene datos faltantes y se van a "completar" usando el **promedio**:

- **promedio** = `df['Columna'].mean()`
- `df.loc[df['Columna'].isnull(), 'Columna'] = promedio`

EJEMPLO DE LIMPIEZA DE DATOS

3) Manejo de valores faltantes:

Otra solución consiste en "**Imputar**" los valores faltantes. Una estrategia simple y efectiva es rellenar los vacíos con la **mediana o la media**. Por ejemplo, supongamos que '**Columna**' tiene datos faltantes y se van a "completar" usando el **promedio**:

- **promedio** = `df['Columna'].mean()`
- `df.loc[df['Columna'].isnull(), 'Columna'] = promedio`

CUIDADO: Imputar puede afectar la distribución de los datos.

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Eliminando columnas no útiles:

Algunas columnas son muy difíciles rellenar de forma precisa, lo más práctico es eliminarla por completo.

- `df.drop(['Columna1','Columna2','Columna3'],axis=1,inplace=True)`

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Conversión de Variables Categóricas a Numéricas:

Los modelos de machine learning necesitan números, no texto. Por ejemplo, es común encontrar columnas como **Sex** es una categoría binaria (male/female). Si este es el caso, se puede convertir fácilmente a números, por ejemplo: **male = 0** y **female = 1**.

- `df['Sex'] = df['Sex'].map({'male': 0, 'female' : 1})`

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Conversión de Variables Categóricas a Numéricas:

En otros casos, hay datos distribuidos en algunas pocas categorías ('A', 'B', 'C'). La mejor técnica aquí puede ser crear una nueva columna para cada puerto (Cat_A, Cat_B, Cat_C) con valores de True o False (en cada fila, solo uno es True).

- `df = pd.get_dummies(df, columns=['Columna'], prefix='Cat')`
- `df = pd.get_dummies(df, columns=['Columna'], prefix='Cat', drop_first=True)`

EJEMPLO DE LIMPIEZA DE DATOS

4) Corrección de errores estructurales: Corrección de registros casi idénticos

Supongamos que tuviéramos errores ortográficos, como una palabra escrita de varias formas: 'Electrónica', 'Electronica', 'electrónica' en la columna 'Area':

- `df['Area'].unique()`
- `df['Area'] = df['Area'].replace({'electronica': 'Electrónica', 'Electronica': 'Electrónica'})`

Esta es una solución “básica”, existen estrategias más completas para hacer este tipo de limpieza.

EJEMPLO DE LIMPIEZA DE DATOS

5) Tratamiento de valores atípicos

Este dataset no tiene este problema, pero supongamos que tuviéramos una edad ('Age') reportada de 200 años.

Podríamos filtrar las edades en un rango realista de 0 a 120 años:

- `df[(df['Age'] > 0) & (df['Age'] < 120)]`

Otra opción es no eliminar el dato, sino atípico, sino imputarlo:

- `valid_mean = df.loc[(df['Age'] > 0) & (df['Age'] < 120), 'Age'].mean()`
- `df.loc[(df['Age'] <= 0) | (df['Age'] >= 120), 'Age'] = valid_mean`

EJEMPLO DE LIMPIEZA DE DATOS

6) Validación

Volver a usar los comandos que se hicieron en el primer paso

- `df.head()`
- `df.info()`
- `df.isnull().sum()`

Los resultados pueden guardarse en un nuevo archivo para no tener que realizar este proceso nuevamente.



Institución
Universitaria
Reacreditada en Alta Calidad

¡MUCHAS GRACIAS!

Material de apoyo usado para las clases de Programación Avanzada
Elaborado por:

Esteban Gonzalez Valencia
estebangonzalez@itm.edu.co

... Hacia una era de
Universidad y Humanidad