

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

1. IDENTIFICACIÓN DE LA GUÍA

Nombre de la guía:	Taller 4
Código de la guía (No.):	001
Taller(es) o Laboratorio(s) aplicable(s):	
Tiempo de trabajo práctico estimado:	8 horas
Asignatura(s) aplicable(s):	Programación Avanzada
Programa(s) Académico(s) / Facultad(es):	Ingeniería Electrónica / Ingeniería de Telecomunicaciones

COMPETENCIAS	CONTENIDO TEMÁTICO	INDICADOR DE LOGRO
C3: Capacidad para aplicar el diseño de ingeniería para generar soluciones que satisfagan necesidades específicas, considerando la salud, la seguridad y el bienestar públicos, así como factores globales, culturales, sociales, ambientales y económicos C5: Capacidad para reconocer las responsabilidades éticas y profesionales en situaciones de ingeniería y emitir juicios fundamentados, considerando el impacto de las soluciones de ingeniería en contextos globales, económicos, ambientales y sociales	Técnicas de limpieza, imputación de valores faltantes y transformación de variables categóricas (One-Hot Encoding). Identificación de patrones, correlaciones y valores atípicos mediante herramientas estadísticas y gráficas (Boxplots e Histogramas).	Propone y ejecuta estrategias de preprocesamiento de datos para asegurar la integridad y utilidad de la información en un entorno de análisis técnico. Evalúa la calidad de la información mediante el análisis de distribuciones y correlaciones, emitiendo juicios técnicos sobre la pertinencia de los datos analizados.

2. FUNDAMENTO TEÓRICO

El análisis de datos moderno en Python se fundamenta en el uso de la librería Pandas, una herramienta diseñada específicamente para la manipulación y el estudio de estructuras de datos tabulares. A diferencia de los arreglos puramente matemáticos de NumPy, Pandas introduce el concepto de DataFrame, que es esencialmente una tabla donde cada columna representa una variable con su propio tipo de dato (numérico, booleano o texto) y cada fila corresponde a una observación específica. Esta estructura permite ejecutar tareas de análisis complejas mediante comandos sencillos y eficientes, facilitando la organización de la información en entornos de ingeniería.

Un componente crítico en cualquier proyecto de ciencia de datos es el Análisis Exploratorio de Datos (EDA). Este proceso consiste en emplear herramientas estadísticas y de visualización para comprender la naturaleza de la información, obtener descripciones estadísticas clave y detectar patrones o relaciones entre las variables. El EDA permite al ingeniero validar la calidad del dataset antes de realizar cualquier modelamiento, asegurando que las conclusiones obtenidas sean coherentes con la realidad del fenómeno estudiado.

Dentro del flujo de trabajo de análisis, la limpieza y el preprocesamiento son pasos obligatorios. Esto incluye la identificación y el manejo de valores nulos (NaN) o duplicados, así como la transformación de variables categóricas mediante técnicas como el One-Hot Encoding. Esta técnica es vital cuando se trabaja con algoritmos que requieren entradas numéricas, ya que evita que el sistema asigne un orden jerárquico incorrecto a etiquetas que son puramente cualitativas.

	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

Finalmente, la visualización estadística actúa como una herramienta de diagnóstico fundamental. El uso de histogramas permite evaluar cambios significativos en la distribución de los datos tras procesos de imputación, mientras que los gráficos de cajas (Boxplots) son esenciales para la detección de valores atípicos o outliers. Identificar estos valores es un paso necesario para garantizar que los análisis de correlación y los modelos posteriores no se vean sesgados por datos erróneos o extremos que no representen el comportamiento general del sistema.

3. OBJETIVOS

Objetivo General:

Capacitar al estudiante en el uso de herramientas computacionales basadas en Python (Pandas, Matplotlib y Seaborn) para realizar un Análisis Exploratorio de Datos (EDA) completo, integrando procesos de limpieza, transformación y visualización estadística de información técnica.

Objetivos Específicos:

- Implementar la carga de datasets desde archivos externos (.csv) y gestionar la información mediante el uso eficiente de DataFrames y Series de Pandas.
- Aplicar técnicas de análisis y limpieza de datos que incluyan la identificación y tratamiento de valores nulos (NaN), la eliminación de registros duplicados, One-Hot Encoding y la imputación de datos mediante criterios estadísticos (media, mediana o moda).
- Generar y analizar histogramas y gráficos de cajas (Boxplots) para evaluar las distribuciones de frecuencia e identificar valores atípicos (outliers) que puedan sesgar los resultados del análisis.
- Cuantificar y visualizar las relaciones de dependencia entre las variables del sistema mediante matrices de correlación y gráficos de dispersión, facilitando la toma de decisiones basada en datos.

4. RECURSOS REQUERIDOS

Los elementos requeridos para realizar el taller son:

- Computador personal con internet.
- Acceso a software tipo Visual Studio Code, Google Colab, Kaggle Notebooks, entre otros.
- Material de estudio entregado en clase (Notebooks).

5. ASPECTOS DE SEGURIDAD

No aplica.

6. PROCEDIMIENTO O METODOLOGÍA PARA EL DESARROLLO

6.1. Para ese taller, usaremos el dataset "Penguins". Utilizaremos la librería seaborn de Python para cargar el dataset directamente en un DataFrame de pandas. Para cargar el dataset, pegar el siguiente código en Colab:

```
# Importar las librerías necesarias
import pandas as pd
import seaborn as sns
```

 Institución Universitaria Reacreditada en Alta Calidad	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

```
# Cargar y mostrar el dataset 'penguins'
df = sns.load_dataset('penguins')
df
```

A continuación, encontrarán la descripción cada una de las Columnas que componen este dataset:

- **species:** La especie del pingüino, tiene tres valores posibles: 'Adelie', 'Chinstrap' y 'Gentoo'. En este análisis, esta será la variable objetivo (la que nos gustaría predecir).
- **island:** La isla en el archipiélago Palmer (Antártida) donde se observó al pingüino. Tiene tres valores: 'Torgersen', 'Biscoe' y 'Dream'.
- **bill_length_mm:** La longitud del pico (culmen) del pingüino en milímetros.
- **bill_depth_mm:** La profundidad (altura) del pico del pingüino en milímetros.
- **flipper_length_mm:** La longitud de la aleta del pingüino en milímetros.
- **body_mass_g:** La masa corporal (peso) del pingüino en gramos.

6.2. Inspeccionar el dataset

- Qué tipo de datos tiene cada columna
- Establezca cuántas columnas tienen valores faltantes y cuántos valores faltan en cada una
- Cuántos registros duplicados tiene el dataset.

6.3. Limpieza de datos.

- Elimine los registros duplicados
- Renombre las columnas usando nombres en español
- Imputar los datos faltantes de longitud, profundidad del pico, masa corporal y longitud de aleta. ¿cuál es la mejor forma de imputar cada columna en particular (media, mediana, moda)?
- Imputar los datos faltantes de sexo. ¿cuál es la mejor forma de imputar esta columna en particular (media, mediana, moda)? Justifique técnicamente si para la columna 'sexo' utilizó la moda o la media, y por qué.
- Analice si fue en realidad es conveniente imputar los datos faltantes en este dataset, o si en su defecto ¿es mejor eliminar las columnas? ¿o eliminar las filas?
- Cambiar las variables categóricas sexo a variables numéricas.
- Cambiar las variables categóricas isla, usando el prefijo 'Isla', convirtiéndolo en tres columnas booleanas.
- Convertir los datos de columna de masa corporal que están en gramos a kilogramos, y renombrar la columna acorde al cambio.

6.4. Distribución de Variables Numéricas

- Genere un histograma para la variable masa corporal.
- Observe la forma del histograma. ¿Los datos siguen una distribución aproximadamente normal (campana de Gauss) o presentan algún sesgo (cola) hacia la derecha o izquierda? Justifique su respuesta comparando la posición de la media y la mediana.
- Genere un gráfico de torta para ver la distribución de las especies de los pingüinos.

6.5. Comparación de Grupos

- Construya un Gráfico de Violín que compare el largo de la aleta (eje Y) según la especie (eje X).
- Análisis: ¿Cuál especie presenta, en promedio, las aletas más largas? Observe la "anchura" del violín en cada especie: ¿qué le indica esto sobre la concentración de los datos en comparación con las otras especies?

- c. Complemente con un Boxplot de la misma variable e identifique si existen valores atípicos (outliers) en alguna de las especies.

6.6. Relación entre Variables

- Genere un gráfico de dispersión (scatter plot) comparando el largo del pico (eje X) frente a la profundidad del pico (eje Y).
- Diferencie los puntos por color según la variable especie.
- ¿Se observan agrupaciones (clusters) claros por especie? ¿La relación entre el largo y la profundidad del pico parece ser lineal o no existe una correlación evidente?

6.7. Utilice un Boxplot para determinar si existe una diferencia significativa en la masa corporal entre machos y hembras".

6.8. ¿Cómo se distribuyen los pingüinos de la especie 'Adelie' entre las tres diferentes islas?

6.9. Utilice un gráfico de dispersión para analizar qué tan fuerte es la correlación entre la masa corporal y el largo de la aleta.

6.10. Matriz de correlación.

- Seleccione únicamente las variables numéricas del dataset (omitir las columnas de correspondiente a las islas).
- Calcule la matriz de correlación de Pearson utilizando el método `.corr()`.
- Genere un mapa de calor (heatmap) con la librería Seaborn, incluyendo los valores numéricos de las celdas (`annot=True`) y configurando el rango de la escala de -1 a 1 (`vmax=1, vmin=-1`).
- Encuentre las correlaciones más fuertes y las correlaciones más débiles del dataset.
- Analice la correlación entre la variable sexo y las demás variables del dataset. ¿Que ve en común? En términos de la vida real, ¿qué significa?

6.11. Análisis del dataset Titanic.

Este dataset es un conjunto de datos clásico en la ciencia de datos que recopila información detallada sobre los pasajeros que abordaron el RMS Titanic en su viaje inaugural en 1912. Este registro permite realizar un Análisis Exploratorio de Datos (EDA) profundo para identificar patrones de supervivencia basados en características demográficas, económicas y familiares, sirviendo como una herramienta fundamental para practicar técnicas de limpieza y preprocesamiento de datos en entornos de ingeniería.

A continuación, se detalla el significado de cada una de las variables que componen este dataset:

- PassengerId:** Identificador único numérico asignado a cada pasajero del barco.
- Survived:** Variable que indica si el pasajero sobrevivió al naufragio (0 = No sobrevivió, 1 = Sobrevivió).
- Pclass:** Clase del ticket de viaje (1 = Primera clase, 2 = Segunda clase, 3 = Tercera clase), la cual actúa como un indicador del nivel socioeconómico del pasajero.
- Name:** Nombre completo y título (como Mr., Mrs., o Miss) del pasajero.
- Sex:** Género del pasajero (male/masculino, female/femenino).
- Age:** Edad del pasajero expresada en años.
- SibSp:** Indica la cantidad de hermanos (*siblings*) o cónyuges (*spouses*) que el pasajero tenía a bordo.
- Parch:** Indica la cantidad de padres (*parents*) o hijos (*children*) que el pasajero tenía a bordo.
- Ticket:** Número o código alfanumérico identificador del boleto de viaje.
- Fare:** Tarifa o precio pagado por el pasajero para realizar el trayecto.
- Cabin:** Código o número de la cabina asignada al pasajero, si se dispone del registro.

 Institución Universitaria Reacreditada en Alta Calidad	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

- **Embarked:** Puerto en el cual el pasajero realizó el embarque: **C** (Cherbourg), **Q** (Queenstown) o **S** (Southampton).

- a. Cargar el dataset ubicado en la siguiente URL

https://github.com/estebangonzalezITM/ProgramacionAvanzada_2026-1/raw/main/Datasets/titanic.csv
dataset.head()

- b. Realizar un análisis exploratorio. Identificar la estructura de los datos, si hay valores duplicados, si hay filas con valores faltantes (y cuantos en cada una).
- c. Renombrar las columnas usando los nombres de las variables en español
- d. Generar histogramas de las distribuciones de los datos.
- e. Identifica el nombre y la edad del pasajero que pagó la tarifa (Fare) más alta y el de la tarifa más baja. Indica también en qué puerto embarcaron.

6.12. Limpieza del dataset.

- a. Eliminar valores duplicados (si aplica).
- b. Imputar los valores faltantes de la columna de edades. Ellos elegir si es conveniente usar la media, la mediana o la moda. Justificar la respuesta
- c. Imputar los valores faltantes de la columna puerto de embarque. Elegir si es conveniente usar la media, la mediana o la moda. Justificar la respuesta
- d. Identificar las columnas que no son de utilidad para implementar modelos estadísticos. Eliminar estas columnas
- e. Convertir la variable sexo a categórica usando '0' y '1'
- f. Convertir la variable puerto de embarque a categórica usando One-Hop Encoding.
- g. Utilizar gráficos de cajas para identificar valores atípicos (outliers).
- h. Filtrar el dataset para eliminar los valores atípicos.
- i. Guardar el dataset limpio en un archivo .csv.

6.13. Análisis del dataset.

- a. Generar histogramas de las columnas de datos que fueron modificadas durante la limpieza. ¿Alguna de las variables sufrió cambios significativos en la distribución de los datos? Evalúe que tan pertinente fue hacer la imputación de estos datos, consulte que alternativas existen.
- b. Genera un gráfico de barras que muestre la cantidad de sobrevivientes y fallecidos según el puerto de embarque.
- c. Crea un gráfico de densidad o un histograma superpuesto que compare la distribución de edades de quienes sobrevivieron frente a los que no. ¿Se confirma la regla de 'niños y mujeres primero'?
- d. Genera una matriz de correlación y visualízala mediante un mapa de calor. Identifique las correlaciones más fuertes (positivas o negativas) entre todas las variables del dataset. ¿Cuáles variables tienen una relación más fuerte con la supervivencia?
- e. Genere gráficos de dispersión que permitan a visualizar estas correlaciones.
- f. Crea una nueva columna llamada FamilySize que sea la suma de hermanos, esposos, padres e hijos más 1 (el propio pasajero). Analiza si el tamaño de la familia influyó en la supervivencia.

 Institución Universitaria Reacreditada en Alta Calidad	GUÍA DE TRABAJO PRÁCTICO - EXPERIMENTAL Talleres y Laboratorios de Docencia ITM	Código	FGL 029
		Versión	03
		Fecha	18-07-2023

7. PARÁMETROS PARA ELABORACIÓN DEL INFORME

No aplica

8. DISPOSICIÓN DE RESIDUOS

No aplica

9. BIBLIOGRAFÍA

- [1] https://github.com/estebangonzalezITM/ProgramacionAvanzada_2026-1
- [2] McKinney, W. (2022). Pandas: Powerful Python data analysis toolkit.
- [3] Healy, K. (2019). Data visualization: A practical introduction

Elaborado por:	<i>Esteban Gonzalez Valencia</i>
Revisado por:	<i>Comité de Inteligencia Computacional</i>
Versión:	<i>1</i>
Fecha:	<i>Mayo de 2026</i>